

3.6. Оптимизация

Важнейшей задачей применения расчетных методов при компьютерном моделировании химико-технологических процессов (ХТП) является определение оптимальных, т.е. наилучших условий их функционирования.

Решение этой задачи возможно при выполнении трех условий:

- выборе критерия оптимальности функционирования ХТП – *целевой функции* R ;
- выявлении ресурсов оптимизации – *независимых переменных оптимизации*

$\bar{x} = [x_1, \dots, x_n]$, оказывающих, по возможности, наибольшее влияние на величину целевой функции;

- реализации метода оптимизации, обеспечивающего определение оптимального (наилучшего) значения целевой функции путем целенаправленного изменения независимых переменных оптимизации.

С математической точки зрения задачи оптимизации следует отнести к типу экстремальных задач.

В общем случае при оптимизации ХТП различают два класса экстремальных задач:

- решение представляется как *совокупность оптимальных значений конечного числа независимых (управляющих) переменных* (в основном, для процессов с сосредоточенными параметрами и описываемых системами конечных уравнений);
- решение представляется как *совокупность неизвестного вида функций* от переменных либо по времени (для динамических процессов, так называемых *распределенных во времени процессов*), либо по пространственной или пространственным координатам (для *распределенных в пространстве процессов*).

В настоящем разделе рассматриваются *методы и алгоритмы решения экстремальных задач первого класса*. Методы решения экстремальных задач второго типа представлены в разд. 5.5.2.

Решение экстремальной задачи первого типа заключается в нахождении совокупности значений независимых (оптимизирующих или управляющих) переменных, при которой заданная целевая функция этих переменных имеет максимальное или минимальное значение. Для решения таких задач разработано достаточно много математических методов, отличающихся стратегией поиска экстремума. Как правило, нельзя рекомендовать какой-то один универсальный метод; для решения конкретной задачи следует учитывать ее особенности и опыт применения различных методов. При поиске экстремума функции многих переменных наибольшее распространение получили методы шагового поиска, реализация которых осуществляется последовательными шагами. Все существующие методы при этом различаются лишь стратегиями выбора направления и величины шага поиска.

В дальнейшем будем полагать, что всегда *ищется экстремум*, являющийся *минимумом заданной целевой функции многих переменных*. Задача на *поиск максимума* сводится к задаче на *поиск минимума простым изменением знака функции*.

В результате задача *оптимизации в узком смысле* (экстремальная задача) может быть записана как

$$\min_{\bar{x}^{\min} \leq \bar{x} \leq \bar{x}^{\max}} R(\bar{x}). \quad (3.6.1)$$

В этом случае отрезок $[\bar{x}^{\min}, \bar{x}^{\max}]$ представляет собой ограничения 1-го рода, накладываемые на независимые переменные, и соответствует области допустимых значений независимых переменных оптимизации, в которой определяются их *оптимальные величины* $(\bar{x}^{opt})$, обеспечивающие *минимум целевой функции* R^{min} :

$$R^{min} = R(\bar{x}^{opt}). \quad (3.6.2)$$

Задача *оптимизации в широком смысле* (*задача нелинейного программирования*) заключается в отыскании экстремума целевой функции при заданных ограничениях в виде равенств и (или) неравенств. Ограничения могут быть линейными и (или) нелинейными.

Пусть непрерывная функция $R(\bar{x})$ представляет собой целевую функцию; $\varphi_1(\bar{x}), \dots, \varphi_m(\bar{x})$ задают ограничения в виде равенств, а $q_{m+1}(\bar{x}), \dots, q_p(\bar{x})$ — ограничения в виде неравенств.

Переменные $\bar{x}(x_1, \dots, x_n)$ могут быть конструктивными параметрами, параметрами режимов, уставками регуляторов и т.п.

Формально *задача нелинейного программирования* может быть сформулирована следующим образом:

$$\text{минимизировать } R(\bar{x}), \quad \bar{x} \in \bar{X}^n \quad (3.6.3)$$

при m линейных и (или) нелинейных ограничениях в виде равенств

$$\varphi_j(\bar{x}) = 0, \quad j = 1, \dots, m \quad (3.6.4)$$

и $(p - m)$ линейных и (или) нелинейных ограничениях в виде неравенств

$$q_j(\bar{x}) \geq 0, \quad j = m+1, \dots, p. \quad (3.6.5)$$

Решение этой задачи соответствует отысканию множества $\bar{x}^* = [x_1^*, \dots, x_n^*]$, удовлетворяющего соотношениям (3.6.4) и (3.6.5) и составляющего экстремум функции $R(\bar{x})$.

По аналогии с экстремальной задачей (3.6.1), задачу нелинейного программирования можно представить следующим образом:

$$\begin{aligned} &\min R(\bar{x}). \\ &\bar{x}^{\min} \leq \bar{x} \leq \bar{x}^{\max} \\ &\varphi_j(\bar{x}) = 0, \quad j = 1, \dots, m \\ &q_j(\bar{x}) \geq 0, \quad j = m+1, \dots, p \end{aligned} \quad (3.6.6)$$

Здесь появляются ограничения 2-го рода в виде предпоследних равенств и последних неравенств, что может существенно усложнить решение задачи оптимизации.

3.6.1. Геометрическая интерпретация задачи оптимизации

В соответствии с соотношением (3.6.3) значение критерия оптимальности R может рассматриваться как функция, определенная в n -мерном пространстве переменных x_j ($j = 1, \dots, n$). Поскольку наглядное графическое изображение n -мерного пространства отсутствует, далее используется следующий прием представления функции $R(\bar{x})$ на плоском чертеже.

Предположим, что через точку x^{opt} в n -мерном пространстве, соответствующую оптимальному решению задачи, например, минимуму целевой функции, проведена двумерная плоскость P . Тогда при удалении от точки x^{opt} по этой плоскости в любом направлении значение $R(\bar{x})$ увеличивается. Если $R(\bar{x})$ является непрерывной функцией в области X , то вокруг точки x^{opt} в данной плоскости всегда можно провести замкнутую линию, вдоль которой значение $R(x)$ постоянно (рис. 3.41, а). Таких замкнутых линий, называемых *линиями постоянного уровня функции* $R(x)$ и отвечающих различным значениям $R(\bar{x}) = c_k$, можно провести в плоскости P вокруг точки x^{opt} сколько угодно, причем каждая из этих линий для точки минимума будет целиком охватывать любую линию, для которой значение функции $R(\bar{x})$ меньше. Форма линий постоянного уровня, соответствующих разным значениям c_k , при этом может существенно различаться.

При наличии ограничений типа равенств (3.6.4) рассмотренный прием изображения целевой функции также можно использовать, если принять во внимание, что каждое из уравнений (3.6.4) определяет в n -мерном пространстве $(n-1)$ -мерную поверхность, пересечение которой с двумерной плоскостью P имеет вид некоторой линии ℓ (см. рис. 3.41, б), вдоль которой и ищется оптимальное решение. Правда, случай, когда число ограничений типа равенств больше 1, пересечения поверхности, например, двумя ограничениями

$$\begin{cases} \varphi_1(x) = 0, \\ \varphi_2(x) = 0 \end{cases} \quad (3.6.7)$$

может иметь с плоскостью P только некоторые общие точки. Однако в большинстве случаев для наглядной иллюстрации метода оптимизации при наличии ограничения типа равенства (3.6.4) достаточно чертежа, изображенного на рис. 3.41, б.

Ограничения же типа неравенств (3.6.5) независимо от их числа наглядно представляются описанным способом на рис. 3.41, в.

Очевидно, что рассмотренный способ изображения функции $R(\bar{x})$ с ограничениями или без них не является однозначным, так как форма линий постоянного уровня функции $R(\bar{x})$ (и форма ограничений) может существенно изменяться в зависимости от ориентации плоскости P в n -мерном пространстве. Тем не менее, изложенный прием во многих случаях позволяет наглядно представить различные принципы действия алгоритмов решения задач нелинейного программирования, вследствие чего он и применяется в дальнейшем.




Рис. 3.41. Геометрическая интерпретация задачи оптимизации: а — без ограничений; б — с одним ограничением в виде равенства; в — с двумя ограничениями в виде неравенств

Особые точки и овраги целевой функции

Как известно, необходимым условием экстремума функции многих переменных является выполнение системы равенств:

$$\frac{\partial R}{\partial x_j} = 0, \quad j = 1, \dots, n. \quad (3.6.8)$$

Поскольку условие (3.6.8) — лишь необходимое, но еще не достаточное, могут представиться случаи, когда при его выполнении в некоторой точке $x^{(s)}$, экстремума функции $R(\bar{x})$ в ней не будет.

Примерами подобных точек целевой функции служат точки, в которых функция $R(\bar{x})$ по одному или нескольким направлениям имеет минимум, в то время как по остальным — максимум. Такие точки называются *седловыми точками* функции $R(\bar{x})$. Для случая двух переменных пример функции с седлом представлен на рис. 3.42.

Линии постоянного уровня на плоскости P , проведенной через седловую точку $x^{(s)}$, изображены на рис. 3.42, где стрелками показаны направления уменьшения значений функции $R(\bar{x})$.

Другим типом особенностей целевой функции являются так называемые *овраги*, при наличии которых вдоль определенных направлений величина данной функции изменяется очень слабо.

В качестве примера можно привести функцию

$$R = \frac{x_1^2}{a^2} + \frac{x_2^2}{b^2} + c^2, \quad (3.6.9)$$

у которой при выполнении условия $a \geq b$ имеется овраг, причем его «дно» расположено вдоль оси x_1 . На рис. 3.43 изображены линии постоянного уровня этой функции.

В общем случае линия «дна» оврага может не совпадать по направлению с осями координат и, кроме того, существенно отличаться от прямой, т.е. возможны также *криволинейные овраги*.

Функции многих переменных могут иметь овраги с размерностью, превышающей 1. Наглядное графическое изображение таких случаев отсутствует, однако формально многомерный овраг можно определить как область значений независимых переменных в n -мерном пространстве, в котором целевая функция вдоль некоторых направлений имеет малую скорость изменения, тогда как вдоль остальных направлений скорость изменения этой функции сравнительно высока.

В качестве примера функции с многомерным оврагом приведем функцию

$$R = \sum_{j=1}^q \frac{x_j^2}{a_j^2} + \sum_{j=q+1}^n \frac{x_j^2}{b_j^2}, \quad (3.6.10)$$

которая при выполнении условия $a_j \geq b_k$ для всех a_j и b_k имеет овраг размерности q .




Рис. 3.42. Линии постоянного уровня в окрестности седловой точки




Рис. 3.43. Характер линий постоянного уровня у функции, имеющей овраг

Как показано ниже, наличие оврагов у оптимизируемой функции затрудняет отыскание истинного положения экстремума, и для точного его нахождения приходится использовать специальные методы поиска.

Глобальный и локальный оптимумы

При отыскании оптимума целевой функции $R(\bar{x})$ (3.6.1) задачей, как правило, является определение совокупности значений независимых переменных x_j , соответствующей не какому-нибудь экстремуму функции $R(\bar{x})$, а наибольшему или наименьшему значению $R(\bar{x})$ в допустимой области X , описываемой соотношениями (3.6.6). В дальнейшем обычно предполагается, что оптимум отвечает наименьшему значению функции $R(\bar{x})$, т.е. совокупность оптимальных значений независимых переменных x_j^{opt} ($j = 1, \dots, n$) при этом удовлетворяет условию:

$$R(\bar{x}^{opt}) < R(\bar{x}), \quad \bar{x} \in \bar{X} \quad (3.6.11)$$

которое выполняется для любых допустимых значений $\bar{x}$.

Оптимум, для которого справедливо условие (3.6.11), обычно называется *глобальным*. Кроме него функция $R(\bar{x})$ может иметь один или несколько *локальных оптимумов* в точках $\bar{x}^{(k)}$ ($k = 1, \dots, p$), для которых можно также записать соотношения типа (3.6.11), выполняющиеся в окрестностях точек $\bar{x}^k \in \bar{X}^k$.

Поскольку заранее число локальных оптимумов p целевой функции не известно, становятся очевидными трудности, которые могут встретиться при отыскании глобального оптимума, так как для этого необходимо найти и проверить все без исключения локальные оптимумы, имеющиеся у целевой функции решаемой задачи. Однако и для определения положения оптимума целевой функции даже в том случае, когда заранее известно, что функция имеет только один оптимум, являющийся глобальным, отыскание решения часто представляет собой задачу далеко не тривиальную, поскольку это связано с операциями поиска в n -мерном пространстве.

3.6.2. Методы оптимизации, основанные на классическом математическом анализе

Необходимые условия существования экстремума функции одной переменной

В основе методов, рассматриваемых в этом разделе, лежит учение классического математического анализа об экстремумах функций одной переменной.

Говорят, что функция $R(x)$, определенная на промежутке $[a, b]$, имеет в точке $x = x_0$ максимум (минимум), если эту точку можно окружить такой окрестностью $(x_0 - \varepsilon, x_0 + \varepsilon)$, содержащуюся в промежутке $[a, b]$, что для всех точек этой окрестности выполняется неравенство:

$$R(x) < R(x_0) \text{ или } R(x) > R(x_0) \text{ для всех } x \neq x_0. \quad (3.6.12)$$

В первом случае максимум — наибольшее значение, во втором минимум — наименьшее значение.

Понятия «максимум» и «минимум» объединяются в одном понятии — экстремум — крайнее (значение).

Необходимое условие существования экстремума функций одной переменной формулируется следующим образом: в точках экстремума производная $dR(x)/dx$ либо

обращается в нуль, либо не существует. Это условие является только необходимым, но не достаточным, т.е. производная dR/dx может быть либо равной нулю, либо не существовать, а экстремума может и не быть.

На рис. 3.44 показан случай, когда необходимое условие выполняется (производная не существует в точке x_0), а экстремума нет. Таким образом, используя необходимое условие существования экстремума, мы можем лишь определить те точки на промежутках, в которых, в принципе, возможен экстремум — «подозрительные» точки.

Итак, чтобы исследовать функцию $R(x)$ на экстремум, надо воспользоваться еще и достаточными условиями существования экстремума.




Рис. 3.44. Случай отсутствия экстремума при выполнении необходимого условия его существования (производная не существует в точке x_0)

Достаточные условия существования экстремума функции одной переменной

Первое достаточное условие. Исследуют поведение функции в ϵ -окрестности «подозрительной» точки, для чего вычисляют:

$$R(x_0 - \delta) \text{ и } R(x_0 + \delta), \quad \text{где } \delta \leq \epsilon. \quad (3.6.13)$$

Если при этом выполняются соотношения:

$$\begin{aligned} R(x_0 - \delta) &< R(x_0); \\ R(x_0 + \delta) &< R(x_0), \end{aligned} \quad (3.6.14)$$

то x_0 есть *точка максимума* (M).

Если:

$$\begin{aligned} R(x_0 - \delta) &> R(x_0); \\ R(x_0 + \delta) &> R(x_0), \end{aligned} \quad (3.6.15)$$

то x_0 есть *точка минимума* (m).

Если условия (3.6.14) и (3.6.15) не соблюдаются, то экстремума в точке нет.

Второе достаточное условие. Исследуют поведение первой производной $\frac{dR}{dx} \equiv R'$ в ϵ -окрестности «подозрительной» точки. Если знак $R'(x_0 - \delta) \neq$ знаку $R'(x_0 + \delta)$, то экстремум в точке x_0 есть. При этом, если $R'(x_0 - \delta) > 0$, а $R'(x_0 + \delta) < 0$, то в точке x_0 максимум; если $R'(x_0 - \delta) < 0$, а $R'(x_0 + \delta) > 0$, то в точке x_0 минимум. Если знак $R'(x_0 + \delta)$ совпадает со знаком $R'(x_0 - \delta)$, то в точке x_0 экстремума нет. Этим правилом следует пользоваться, когда R' вычислить легче, чем R .

Третье достаточное условие. Исследуют знак высших производных непосредственно в точках, подозреваемых на экстремум. Правилom можно воспользоваться, если $R(x)$ — непрерывная функция и имеет непрерывные производные высших порядков. Тогда, если $R''(x_0) > 0$, то в точке x_0 имеем минимум, если $R''(x_0) < 0$, то в точке x_0 имеем максимум, если $R''(x_0) = 0$, то необходимо исследовать знаки высших производных. При этом применяется следующее правило: если первая, не обращающаяся в нуль производная нечетного порядка, то в исследуемой точке нет ни максимума, ни минимума; если же эта производная четного порядка, то имеется максимум, при условии, что она отрицательна, и минимум, если она положительна.

Пример. $R(x) = x^3$; $R'(x) = 3x^2$; таким образом, точка $x_0 = 0$ — «подозрительная» (по необходимому условию).

▼ Вычисляем: при $x = 0$ $R''(x) = 6x = 0$; $R'''(x) = 6$; $R''' \neq 0$, следовательно, экстремума нет, так как порядок производной 3 — нечетный. Пусть теперь $R(x) = x^4$; $R'(x) = 4x^3 \Rightarrow x_0 = 0$ — «подозрительная» точка. Вычисляем: при $x = 0$ $R''(x) = 12x^2 = 0$; $R'''(x) = 24x = 0$; $R^{IV}(x) = 24 \neq 0$. Порядок производной четный и $R^{IV} > 0$, следовательно, в точке $x = 0$ имеем минимум. ▲

Однако в конкретных задачах химической технологии не всегда бывает необходимо проверять достаточные условия существования экстремума. Иногда *достаточность следует из законов химии и химической технологии*.

Необходимые условия существования экстремума функции многих переменных

Функция многих переменных $R(x_1, x_2, \dots, x_n)$ имеет в точке $(x_1^0, x_2^0, \dots, x_n^0)$ максимум (минимум), если существует такая окрестность этой точки, взятая из области определения функции, что для всех точек этой окрестности справедливо следующее неравенство:

$$R(x_1, x_2, \dots, x_n) < R(x_1^0, x_2^0, \dots, x_n^0) \quad (3.6.16)$$

или

$$R(x_1, x_2, \dots, x_n) > R(x_1^0, x_2^0, \dots, x_n^0).$$

Необходимым условием существования экстремума функции многих переменных является равенство нулю частных производных первого порядка по всем переменным, т.е.

$$\left(\frac{\partial R}{\partial x_i} \right)_{\vec{x}=\vec{x}^0} = 0; \quad \left(\frac{\partial R}{\partial x_2} \right)_{\vec{x}=\vec{x}^0} = 0; \quad \left(\frac{\partial R}{\partial x_n} \right)_{\vec{x}=\vec{x}^0} = 0. \quad (3.6.17)$$

В этом случае полный дифференциал дифференцируемой функции R равен нулю:

$$dR(x_1, x_2, \dots, x_n) = 0. \quad (3.6.18)$$

В самом деле, так как

$$dR(x_1, x_2, \dots, x_n) = \frac{\partial R}{\partial x_1} dx_1 + \frac{\partial R}{\partial x_2} dx_2 + \dots + \frac{\partial R}{\partial x_n} dx_n = \sum_{i=1}^n \frac{\partial R}{\partial x_i} dx_i,$$

и $\frac{\partial R}{\partial x_i} = 0$ по условию (3.6.17), следовательно, $dR(x_1, x_2, \dots, x_n) = 0$.

Достаточные условия существования экстремума функции многих переменных формулируются значительно сложнее, чем для функции одной переменной.

Достаточные условия существования экстремума функции многих переменных

Разложим функцию $R(x_1, x_2, \dots, x_n)$ в окрестности точки $(x_1^0, x_2^0, \dots, x_n^0)$, исследуемой на экстремуме, в ряд Тейлора по степеням Δx_i :

$$R(x_1^0 + \Delta x_1, x_2^0 + \Delta x_2, \dots, x_n^0 + \Delta x_n) = R(x_1^0, x_2^0, \dots, x_n^0) + \sum_{i=1}^n \left(\frac{\partial R}{\partial x_i} \right) \Delta x_i + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 R}{\partial x_i \partial x_j} \Delta x_i \Delta x_j + \dots \quad (3.6.19)$$

Но по необходимому условию (3.6.17) имеем:

$$\sum_{i=1}^n \frac{\partial R}{\partial x_i} \Delta x_i = 0. \quad (3.6.20)$$

Далее, если выражение $\sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 R}{\partial x_i \partial x_j} \Delta x_i \Delta x_j$ сохраняет один и тот же знак для любых приращений Δx_i и Δx_j , то экстремум есть. Обозначая

$$\frac{\partial^2 R}{\partial x_i \partial x_j} = a_{ij}; \quad \Delta x_i = z_i; \quad \Delta x_j = z_j, \quad (3.6.21)$$

это выражение примет вид:

$$\sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 R}{\partial x_i \partial x_j} \Delta x_i \Delta x_j = \sum_{i=1}^n \sum_{j=1}^n a_{ij} z_i z_j = z^{(2)}. \quad (3.6.22)$$

При этом полученное выражение для определения $z^{(2)}$ называется *квадратичной формой*.

Если при любых значениях z_i и z_j , $z^{(2)}$, кроме $z_i = 0$ и $z_j = 0$, величина $z^{(2)} > 0$, а в точке $z_i = 0$ и $z_j = 0$ величина $z^{(2)} = 0$, то *квадратичная форма* $z^{(2)}$ (3.6.22) называется *положительно определенной*, что соответствует *минимуму целевой функции* $R(x_1, x_2, \dots, x_n)$.

Условие положительной определенности квадратичной формы (3.6.22) формулируется следующим образом.

Квадратичная форма будет положительно определенной в том случае, если все определители, составленные из элементов a_{ij} , положительны, т.е.

$$a_{11} > 0; \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} > 0; \dots; \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix} > 0. \quad (3.6.23)$$

Условия (3.6.23) носят название условий Сильвестра, а определители в этих неравенствах называются определителями Сильвестра.

Итак, если *все определители Сильвестра положительны*, то имеет место минимум целевой функции; если *опредетелители Сильвестра нечетного порядка отрицательны*, а *четного порядка — положительны*, то имеет место максимум целевой функции; а если последовательность чередования знаков у определителей Сильвестра иная, то экстремума у целевой функции нет.

Для случая 2-х переменных определим условия минимума и максимума целевой функции, а также отсутствие экстремума с помощью определителей Сильвестра (3.6.23).

$$\text{Если: } \left. \begin{array}{l} \frac{\partial^2 R}{\partial x_1^2} > 0 \\ \frac{\partial^2 R}{\partial x_1^2} \cdot \frac{\partial^2 R}{\partial x_2^2} - \left(\frac{\partial^2 R}{\partial x_1 \partial x_2} \right)^2 > 0 \end{array} \right\} \Rightarrow \text{минимум.} \quad (3.6.24)$$

$$\text{Если: } \left. \begin{array}{l} \frac{\partial^2 R}{\partial x_1^2} < 0 \\ \frac{\partial^2 R}{\partial x_1^2} \cdot \frac{\partial^2 R}{\partial x_2^2} - \left(\frac{\partial^2 R}{\partial x_1 \partial x_2} \right)^2 > 0 \end{array} \right\} \Rightarrow \text{максимум.} \quad (3.6.25)$$

$$\text{Если: } \left. \begin{aligned} \frac{\partial^2 R}{\partial x_1^2} < 0 \\ \frac{\partial^2 R}{\partial x_1^2} \cdot \frac{\partial^2 R}{\partial x_2^2} - \left(\frac{\partial^2 R}{\partial x_1 \partial x_2} \right)^2 < 0 \end{aligned} \right\} \Rightarrow \text{экстремума нет.} \quad (3.6.26)$$

3.6.3. Методы оптимизации для решения экстремальных задач с ограничениями типа равенств

Пусть требуется найти экстремум функции $R(x_1, x_2, \dots, x_n)$ с n переменными, причем эти переменные связаны между собой дополнительными условиями вида:

$$\varphi_j(x_1, x_2, \dots, x_n) = 0, \quad j = 1, 2, \dots, m. \quad (3.6.27)$$

(Это часто встречаемая задача оптимизации процессов химической технологии, для которых $R(x_1, x_2, \dots, x_n)$ является критерием оптимальности, а уравнения вида (3.6.27) представляют собой уравнения математического описания.)

Для данной постановки задачи должно быть выполнено условие $m < n$. В противном случае, т.е. при $m \geq n$, если система имеет решение, то это решение представляет собой набор дискретных точек, причем решение оптимальной задачи сводится в этом случае к проверке значений R , вычисленных в этих точках, и экстремальная задача решается обычным перебором.

Экстремум функции $R(x_1, x_2, \dots, x_n)$ с ограничениями вида (3.6.27) носит название *условного экстремума* [(экстремум при условии, что выполняются соотношения (3.6.27))].

Для определения условного экстремума (при $m < n$) наиболее просто применить следующий прием: выразить m переменных (так называемых зависимых переменных) через остальные $(n-m)$ переменных, т.е. получить соотношения вида:

$$x_k = f_k(x_{m+1}, x_{m+2}, \dots, x_n). \quad (3.6.28)$$

Затем подставить эти зависимости в выражение функции $R(x_1, x_2, \dots, x_n)$ и получить функцию:

$$\begin{aligned} R^* &= R[f_1(x_{m+1}, \dots, x_n), f_2(x_{m+1}, \dots, x_n), \dots, f_m(x_{m+1}, \dots, x_n), x_{m+1}, x_{m+2}, \dots, x_n] = \\ &= R^*(x_{m+1}, x_{m+2}, \dots, x_n), \end{aligned} \quad (3.6.29)$$

в которой переменные $x_{m+1}, x_{m+2}, \dots, x_n$ являются уже независимыми.

Далее находится экстремум функции R^* с $(n-m)$ независимыми переменными обычными способами, т.е. определяются значения $x_{m+1}^0, x_{m+2}^0, \dots, x_n^0$, составляющие экстремум функции R^* или, что то же самое, R . По известным значениям $x_{m+1}^0, x_{m+2}^0, \dots, x_n^0$ и по формулам (3.6.28) определяются остальные значения переменных в точке экстремума $x_1^0, x_2^0, \dots, x_m^0$. Таким образом, задача определения условного экстремума $R(x_1, x_2, \dots, x_n)$ сведена к задаче определения экстремума функции $R^*(x_{m+1}, x_{m+2}, \dots, x_n)$, в которой переменные $x_{m+1}, x_{m+2}, \dots, x_n$ являются независимыми.

Однако этот способ решения задачи отыскания условного экстремума обычно бывает неприменим из-за трудности или невозможности разрешить систему (3.6.27) относительно переменных в виде (3.6.28). Тогда задачи на условный экстремум решаются *методом неопределенных множителей Лагранжа*.

Метод неопределенных множителей Лагранжа

Пусть $\bar{x}^0 = (x_1^0, x_2^0, \dots, x_n^0)$ есть экстремум функции $R(x_1, x_2, \dots, x_n)$ при наличии связей между переменными вида (3.6.27):

$$\varphi_j(x_1, x_2, x_3, \dots, x_n) = 0 \quad (j = 1, \dots, m < n), \quad (3.6.30)$$

т.е. является условным экстремумом.

Запишем необходимое условие существования экстремума функции многих переменных (3.6.16), предполагая дифференцируемость функции R по всем переменным:

$$\sum_{i=1}^n \left(\frac{\partial R}{\partial x_i} \right)_{\bar{x}^0} dx_i = 0. \quad (3.6.31)$$

При этом не все дифференциалы dx_i являются независимыми, так как на переменные x_i наложены дополнительные условия (3.6.27).

Далее, предполагая, что функции φ_j также дифференцируемы по всем переменным, запишем полный дифференциал функции φ_j в точке экстремума:

$$d\varphi_j = \sum_{i=1}^n \left(\frac{\partial \varphi_j}{\partial x_i} \right)_{\bar{x}^0} dx_i = 0 \quad (j = 1, \dots, m), \quad (3.6.32)$$

причем очевидно, что полный дифференциал функции $d\varphi_j$ равен нулю, так как правая часть соотношения (3.6.32) равна нулю.

Сделаем следующие конструктивные построения. Умножим каждое из полученных равенств (3.6.32) на некоторый множитель λ_j и сложим с соотношением (3.6.31). При этом получим:

$$\sum_{i=1}^n \left(\frac{\partial R}{\partial x_i} \right)_{\bar{x}^0} dx_i + \sum_{j=1}^m \lambda_j \sum_{i=1}^n \left(\frac{\partial \varphi_j}{\partial x_i} \right)_{\bar{x}^0} dx_i = 0 \quad (3.6.33)$$

или

$$\sum_{i=1}^n \left(\frac{\partial R}{\partial x_i} + \lambda_1 \frac{\partial \varphi_1}{\partial x_i} + \lambda_2 \frac{\partial \varphi_2}{\partial x_i} + \dots + \lambda_m \frac{\partial \varphi_m}{\partial x_i} \right)_{\bar{x}^0} dx_i = 0. \quad (3.6.34)$$

Так как правые части соотношений (3.6.31) и (3.6.32) равны нулю, то и в правой части соотношений (3.6.33) и (3.6.34) должны стоять нули.

Как мы уже подчеркивали ранее, дифференциалы dx_i не все являются независимыми, а только последние $(n - m)$ дифференциалов. Попробуем исключить m зависимых дифференциалов из выражения (3.6.34) таким выбором множителей λ_j , чтобы коэффициенты при этих дифференциалах обратились в нуль. Это условие запишется следующим образом:

$$\left(\frac{\partial R}{\partial x_i} + \lambda_1 \frac{\partial \varphi_1}{\partial x_i} + \lambda_2 \frac{\partial \varphi_2}{\partial x_i} + \dots + \lambda_m \frac{\partial \varphi_m}{\partial x_i} \right)_{\bar{x}^0} = 0 \quad \text{при } i = 1, 2, \dots, m. \quad (3.6.35)$$

Левая часть соотношения (3.6.35) представляет собой коэффициент при i -м зависимом дифференциале. Очевидно, что соотношение (3.6.35) представляет собой систему из m уравнений, по которой могут быть определены m множителей λ_j (если они существуют).

Из соотношения (3.6.34) исключим нулевые члены (3.6.35). Тогда в этом соотношении останутся только независимые дифференциалы dx_i ($i = m+1, \dots, n$):

$$\sum_{i=m+1}^n \left(\frac{\partial R}{\partial x_i} + \lambda_1 \frac{\partial \varphi_1}{\partial x_i} + \lambda_2 \frac{\partial \varphi_2}{\partial x_i} + \dots + \lambda_m \frac{\partial \varphi_m}{\partial x_i} \right) dx_i = 0. \quad (3.6.36)$$

Но для того чтобы сумма в левой части (3.6.36) равнялась нулю при независимых (произвольных) dx_i ($i = m+1, m+2, \dots, n$) достаточно, чтобы коэффициент при каждом независимом дифференциале был равен нулю, т.е.

$$\left(\frac{\partial R}{\partial x_i} + \lambda_1 \frac{\partial \varphi_1}{\partial x_i} + \lambda_2 \frac{\partial \varphi_2}{\partial x_i} + \dots + \lambda_m \frac{\partial \varphi_m}{\partial x_i} \right)_{x^0} = 0; \quad i = m+1, m+2, \dots, n \quad (3.6.37)$$

со значениями λ_j , определенными по соотношению (3.6.35).

Объединяя равенства (3.6.35) и (3.6.37), получим

$$\left(\frac{\partial R}{\partial x_i} + \lambda_1 \frac{\partial \varphi_1}{\partial x_i} + \lambda_2 \frac{\partial \varphi_2}{\partial x_i} + \dots + \lambda_m \frac{\partial \varphi_m}{\partial x_i} \right)_{x^0} = 0; \quad i = 1, 2, \dots, n. \quad (3.6.38)$$

Системе (3.6.38) должны удовлетворять как λ_j ($j = 1, 2, \dots, m$), так и x_i^0 ($i = 1, 2, \dots, n$). Кроме того, x_i^0 должны удовлетворять системе (3.6.27).

Таким образом, мы получаем систему из $(n+m)$ уравнений для $(n+m)$ неизвестных (m значений λ_j и n значений x_i^0).

Для удобства полученную систему (3.6.38) с учётом (3.6.27) запишем в форме Лагранжа, для чего введем функцию Лагранжа

$$\Phi = R + \sum_{j=1}^m \lambda_j \varphi_j. \quad (3.6.39)$$

Тогда система уравнений (3.6.38) и (3.6.27) примет вид:

$$\begin{cases} \left(\frac{\partial \Phi}{\partial x_i} \right)_{x^0} = 0, & i = 1, 2, \dots, n; \\ \left(\frac{\partial \Phi}{\partial \lambda_j} \right)_{x^0} = 0, & j = 1, 2, \dots, m. \end{cases} \quad (3.6.40)$$

Используя данный прием, задача на условный экстремум снова сводится к задаче определения экстремума функции Φ вместо R . При решении системы $(n+m)$ уравнений с $(n+m)$ неизвестными (m значений λ_j и n значений x_i^0), получаются оптимальные значения x_i^0 ($i = 1, \dots, n$) с учетом ограничений в виде равенств (3.6.27).

3.6.4. Численные методы оптимизации без ограничений

Если целевая функция не является унимодальной (т.е. имеющей один экстремум), то могут существовать различные типы решений (локальный и глобальный экстремумы). Для задач, соответствующих действительным физическим параметрам процессов, целевая функция обычно является приемлемой, так как обладает единственным экстремумом. Поэтому для большинства практических целей локальное решение задачи не является существенным недостатком. В случае множественных оптимумов полезны понятия вогнутости и выпуклости при определении того, при каких условиях локальное оптимальное решение является также глобальным опти-

мумом. Функция $R(\bar{x})$ называется *выпуклой* в области G , если для любых двух векторов $\bar{x}_1$ и $\bar{x}_2 \in G$

$$R(\theta \bar{x}_1 + (1-\theta)\bar{x}_2) \leq \theta R(\bar{x}_1) + (1-\theta)R(\bar{x}_2), \quad (3.6.41)$$

где θ — скалярная величина, изменяющаяся в диапазоне $0 \leq \theta \leq 1$. Функция $R(\bar{x})$ является *строго выпуклой*, если для $\bar{x}_1 \neq \bar{x}_2$ в выражении (3.6.41) не используется знак равенства.

На рис. 3.45, а изображена строго выпуклая функция одной независимой переменной; выпуклая функция не может принимать значения большего, чем значения функции, полученной линейной интерполяцией между $R(\bar{x}_1)$ и $R(\bar{x}_2)$. Если имеет место неравенство, обратное (3.6.41), то функция называется *вогнутой* (рис. 3.45, б).

Дифференцируемая выпуклая функция обладает следующими свойствами:

$$1) \quad R(\bar{x}_1) - R(\bar{x}_2) \geq \bar{\nabla} R(\bar{x}_1)(\bar{x}_1 - \bar{x}_2) \quad (3.6.42)$$

для всех $\bar{x}_1, \bar{x}_2$, где $\bar{\nabla} R(\bar{x}_1)$ — градиент функции $R(\bar{x})$ в точке $\bar{x}_1$:

$$\bar{\nabla} R(\bar{x}^*) = \begin{bmatrix} \frac{\partial R(\bar{x}^*)}{\partial x_1} \\ \dots \\ \frac{\partial R(\bar{x}^*)}{\partial x_n} \end{bmatrix}; \quad (3.6.43)$$

2) матрица вторых частных производных $R(\bar{x})$ по $\bar{x}$ [матрица Гесса — $H(\bar{x}^*)$] положительно определенная (или положительно полуопределенная) для всех $\bar{x}$, если $R(\bar{x})$ строго выпуклая (или просто выпуклая):

$$\bar{\nabla}^2 R(\bar{x}^*) = H(\bar{x}^*) = \begin{bmatrix} \frac{\partial^2 R(\bar{x}^*)}{\partial x_1^2} & \dots & \frac{\partial^2 R(\bar{x}^*)}{\partial x_1 \partial x_n} \\ \dots & \dots & \dots \\ \frac{\partial^2 R(\bar{x}^*)}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 R(\bar{x}^*)}{\partial x_n^2} \end{bmatrix}; \quad (3.6.44)$$

3) в области G функция $R(\bar{x})$ имеет только один экстремум.

Требование унимодальности функции является значительно более слабым, чем требование вогнутости или выпуклости, поскольку унимодальность не требует ни непрерывности, ни единственности производной.

В нелинейном программировании большое внимание уделяется определению необходимых и достаточных условий того, чтобы некоторый вектор решения $\bar{x}^*$ являлся локальным экстремумом.




Рис. 3.45. Строго выпуклая функция вниз (а) и строго выпуклая функция вверх (б) от одной независимой переменной

При отсутствии ограничений необходимыми условиями того, что $\bar{x}^*$ — точка локального минимума, являются:

- 1) функция $R(\bar{x})$, дифференцируемая в точке $\bar{x}^*$;
- 2) $\nabla R(\bar{x}^*) = 0$, т.е. существование стационарной точки в $\bar{x}^*$.

Достаточные условия того, что $\bar{x}^*$ — точка локального минимума (максимума), кроме условий 1 и 2 включают следующее:

- 3) $\nabla^2 R(\bar{x}^*) > 0$ ($\nabla^2 R(\bar{x}^*) < 0$), т.е. матрица Гесса положительно определенная (отрицательно определенная).

Непосредственное использование этих условий связано зачастую со значительными трудностями и поэтому оптимизационные процедуры носят характер поиска по следующей общей методике:

- 1) выбирается некоторая начальная точка $\bar{x}^0 = (x_1^0, x_2^0, \dots, x_n^0)$; выбор этот произволен, зависит от интуиции исследователя и существенно влияет на скорость решения задачи;
- 2) по какому-нибудь признаку выбирается направление, в котором ожидается найти оптимальную точку;
- 3) в выбранном направлении делается либо один шаг, либо множество шагов в зависимости от степени их успешности.

Направление в n -мерном пространстве задается с помощью вектора, содержащего n координат, т.е. с помощью n чисел.

Например, на плоскости пары чисел определяют направления $\begin{pmatrix} -\frac{1}{2}, \frac{1}{2} \end{pmatrix}$; $\begin{pmatrix} -\frac{1}{4}, -\frac{1}{2} \end{pmatrix}$; $\begin{pmatrix} \frac{1}{2}, \frac{1}{2} \end{pmatrix}$ и т.п. (рис. 3.46).

Таким образом, для любого направления существует пара чисел, которая единственным образом его определяет.

Аналогично определяется направление в n -мерном пространстве как n -мерный вектор.

Пусть задан некоторый n -мерный вектор $\bar{s} = (s_1, s_2, \dots, s_n)$ и начальная точка $\bar{x}^0 = (x_1^0, x_2^0, \dots, x_n^0)$, тогда сделать шаг величины L в направлении $\bar{s}$ из точки $\bar{x}_0$ — значит определить новую точку $\bar{x}^1 = (x_1^1, x_2^1, \dots, x_n^1)$, которая находится от $\bar{x}_0$ на расстоянии L :

$$\bar{x}^1 = \bar{x}^0 + L\bar{s} \quad (3.6.45)$$

или

$$x_i^1 = x_i^0 + Ls_i, \quad i = 1, 2, \dots, n. \quad (3.6.46)$$

Существует два подхода при движении по заданному направлению.

Первый: по заданному направлению делается шаг произвольной длины и, если полученная точка успешная (движение происходит в направлении оптимума), то в новой точке определяются новое направление и процедура повторяется (градиентный метод, релаксационный и т.д.).

Второй: в заданном направлении ищется минимум целевой функции $f(\bar{x})$, т.е. решается задача $\min_{\bar{x}} f(\bar{x}^0 + L\bar{s})$. В найденной новой точке $\bar{x}^1$ определяется новое направление, и процедура повторяется (метод крутого восхождения, метод Гаусса и т.д.).

Все существующие методы безусловной оптимизации отличаются друг от друга способом выбора направлений и методом определения необходимого движения в принятом направлении. По способу выбора направления они разделяются на гради-




Рис. 3.46. Задание различных направлений поиска при реализации алгоритма оптимизации




Рис. 3.47. Графическая иллюстрация проблемы, связанной с определением экстремума при поиске оптимума функции с криволинейным оврагом

ентные и методы поиска, т.е. не использующие градиент. Такое обилие методов объясняется тем, что все они имеют разную скорость сходимости, и их выбор существенно зависит от вида оптимизируемой функции.

Так, например, простая на вид функция (полином 4-го порядка)

$$f(x_1, x_2) = 100(x_2^2 - x_1)^2 + (1 - x_1)^2$$

имеет следующий вид (рис. 3.47), где сплошные линии (линии уровня) обозначают точки, в которых $f(x_1, x_2) = \text{const}$. Пунктирная линия обозначает «дно» оврага, вдоль которого функция убывает очень слабо, зато на стенках она убывает сильно, что создает значительные трудности при отыскании экстремума. Поэтому любой метод с применением поиска в одном направлении «скатывается» на «дно» оврага и медленно движется вдоль него.

Прямые методы поиска экстремума функции одной переменной

Прямые методы в качестве критерия движения к экстремуму используют сравнительную оценку величины целевой функции, вычисленной в соответствующих точках. Следует отметить, что прямые методы поиска экстремума функции одной переменной имеют не только самостоятельное значение, но и широко используются как вспомогательные методы при поиске экстремума функции многих переменных.

Метод сканирования

Интервал поиска $[x_{\min}, x_{\max}]$ разбивается на n равных участков, длина каждого из которых равна шагу поиска h (рис. 3.48). Далее последовательно определяется значение функции во всех точках разбиения и в точках $x_{\min}$ и $x_{\max}$ и запоминается наименьшее значение. Таким образом, экстремум может быть найден с точностью до шага поиска. Основным достоинством метода является его простота и возможность нахождения глобального экстремума. Недостатком метода является большой объем вычислений, которые необходимо выполнять при его реализации.




Рис. 3.48. Графическая иллюстрация метода сканирования




Рис. 3.49. Графическая иллюстрация метода локализации экстремума

Метод локализации экстремума

Метод локализации представляет собой модификацию метода сканирования. При его использовании существенно снижается количество выполняемых вычислений.

Весь интервал поиска $[x_{\min}, x_{\max}]$, как и в методе сканирования, разбивается на несколько частей (подынтервалов) точками x_1, x_2 и x_3 , но более крупных размеров (рис. 3.49).

Вычисляется значение критерия $R(x)$ во всех точках разбиения и в точках $x_{\min}$ и $x_{\max}$. Все значения $R(x)$ сравниваются между собой и из них оставляется наименьшее, если ищем минимум, и наибольшее, если ищем максимум. Далее выбирается новый интервал поиска, равный двум подынтервалам, с наименьшим (наибольшим) вычисленным значением R на их общей границе (на рисунке это соответствует интервалу $[x_{\min}, x_2]$). Этот интервал меньше исходного, и в нем локализован экстремум. Затем поступают следующим образом. Интервал, в котором локализован экстремум, делят на несколько подынтервалов (на рисунке точками 1 и 2) и снова вычисляют значения критерия оптимальности в точках деления. Сравнивают их между собой, находят наименьшее, локализуют экстремум в меньшем интервале (на рисунке в интервале 1–2) и т.д. до тех пор, пока экстремум не будет локализован в интервале, размер которого соответствует заданной точности поиска.

Наилучшие результаты поиска получаются в том случае, когда первоначальный интервал $[x_{\min}, x_{\max}]$ разбивается на четыре подынтервала ($n = 4$). При этом каждый последующий подынтервал делится пополам, и вычислять значение функции нужно только в двух новых точках, так как ее значения на концах нового интервала и в его середине известны из предыдущих расчетов.

Абсолютная ошибка в нахождении экстремума в этом случае определяется выражением:

$$\Delta = (x_{\max} - x_{\min}) \cdot 2^{-\frac{s-1}{2}}, \quad (3.6.47)$$

где s — количество точек, в которых вычисляется значение критерия оптимальности.

Так, при $s = 21$ относительная ошибка составит:

$$\frac{\Delta}{x_{\max} - x_{\min}} = 2^{-10} \approx 0,001. \quad (3.6.48)$$

Метод золотого сечения

В основе этого метода лежит правило геометрического отношения или золотого сечения:

$$\frac{a}{b} = \frac{b}{c} \quad \text{или} \quad ac = b^2, \quad (3.6.49)$$

где a — длина всего отрезка; b — длина его большей части; c — длина его меньшей части.

В соответствии с этим законом определяются точки исследуемого интервала, в которых необходимо производить вычисление целевой функции R .

Из рис. 3.50 следует, что:

$$c = a - b. \quad (3.6.50)$$

Тогда, подставляя в (3.6.49) соотношение (3.6.50) получим:

$$a(a - b) = b^2. \quad (3.6.51)$$

Обозначив отношение $b/a = k$ и подставив его в (3.6.51), получим:

$$a^2 k^2 + a^2 k - a^2 = 0, \quad (3.6.52)$$

откуда следует:

$$k^2 + k - 1 = 0. \quad (3.6.53)$$

Решение этого уравнения дает:

$$k = \frac{-1 \pm \sqrt{1+4}}{2} = \frac{-1 \pm \sqrt{5}}{2}. \quad (3.6.54)$$

Поскольку $k > 0$, то его значение принимается равным:

$$k = \frac{-1 + \sqrt{5}}{2} \approx 0.62. \quad (3.6.55)$$

Порядок поиска экстремума методом золотого сечения будет следующий.

На исследуемом интервале $[x_{min}, x_{max}]$ определяются две точки (рис. 3.51):

$$\begin{cases} x_1 = x_{min} + k^2 a; \\ x_2 = x_{min} + ka, \end{cases} \quad (3.6.56)$$

где a — длина интервала $[x_{min}, x_{max}]$.

В точках x_1 и x_2 рассчитываются значения целевой функции R . По найденным значениям $R(x_1)$ и $R(x_2)$ определяется подынтервал, в котором локализован экстремум. Этот подынтервал состоит из двух подынтервалов не равной длины.

На рис. 3.51 минимальное значение будет $R(x_1)$ в точке x_1 . Подынтервал, в котором локализован экстремум, будет $[x_{min}, x_2]$. Далее внутри большего подынтервала (в нашем примере внутри $[x_{min}, x_1]$) находится точка, отстоящая от общего конца интервала на расстояние




Рис. 3.50. Графическая иллюстрация правила золотого сечения




Рис. 3.51. Графическая иллюстрация метода золотого сечения

k^2b , где b — длина подынтервала, в котором локализован экстремум $[x_{\min}, x_2]$, причем $b = ka$.

В нашем примере это будет

$$x_3 = x_{\min} + k^2(ka) = x_{\min} + k^3a. \quad (3.6.57)$$

Нетрудно заметить, что величина интервала $[x_1, x_2]$ также равна k^3a . В самом деле, величина $([x_{\min}, x_2])$ равна ka , тогда величина $(x_2 - x_1)$ будет определяться:

$$ka - k^2a = ka(1 - k) = k^3a, \quad (3.6.58)$$

так как $(1 - k)$ из уравнения (3.6.53) равно k^2 .

Таким образом, $(x_2 - x_1) = (x_3 - x_{\min})$, следовательно, рассчитывать длину интервала $[x_{\min}, x_3]$ нет необходимости.

Далее вычисляется $R(x_3)$, и сравниваются значения $R(x_2)$, $R(x_1)$ и $R(x_3)$. Находится минимальное [в примере $R(x_3)$] и процедура продолжается до достижения требуемой точности.

Абсолютная ошибка в определении экстремума после s вычислений будет:

$$\Delta = \frac{x_{\max} - x_{\min}}{2} \cdot \left(\frac{\sqrt{5} - 1}{2} \right)^{s-3}, \quad (3.6.59)$$

и для $s = 21$ относительная ошибка есть:

$$\frac{\Delta}{x_{\max} - x_{\min}} = \frac{1}{2} \cdot 0.62^{18} \approx 0.9 \cdot 10^{-4}, \quad (3.6.60)$$

т.е. точность расчета значительно превосходит точность расчета по методу локализации при одном и том же количестве вычислений.

Метод поиска с использованием чисел Фибоначчи

Последовательность чисел Фибоначчи, определяемая рекуррентным соотношением

$$F_n = F_{n-1} + F_{n-2}; \quad F_0 = F_1 = 1, \quad (3.6.61)$$

может быть использована для организации поиска экстремума функции одной переменной. Причем абсолютная погрешность, возникающая при поиске этим методом, не превышает величины

$$\Delta = \frac{x_{\max} - x_{\min}}{F_s}, \quad (3.6.62)$$

где F_s — s -е число в последовательности чисел Фибоначчи.

Таблица этой последовательности до $s = 12$ приведена ниже:

s	1	2	3	4	5	6	7	8	9	10	11	12
F_s	1	2	3	5	8	13	21	34	55	89	144	233

При выполнении $s = 21$ вычислений точность определения экстремума составляет

$$\frac{\Delta}{x_{\max} - x_{\min}} = \frac{1}{F_{21}} \approx 0.56 \cdot 10^{-4}, \quad (3.6.63)$$

т.е. оказывается еще более высокой, чем в методе золотого сечения.

Ниже приведен порядок поиска экстремума с использованием чисел Фибоначчи.

1. По заданной точности Δ поиска рассчитывается вспомогательное число:

$$N = \frac{x_{\max} - x_{\min}}{\Delta}. \quad (3.6.64)$$

2. Находится число Фибоначчи F_s , такое, что:

$$F_{s-1} < N \leq F_s. \quad (3.6.65)$$

3. Определяется минимальный шаг поиска:

$$h_{\min} = \frac{x_{\max} - x_{\min}}{F_s}. \quad (3.6.66)$$

4. Рассчитывается значение R в точке, определяемой соотношением:

$$x_1 = x_{\min} + h_{\min} F_{s-2}. \quad (3.6.67)$$

5. Рассчитывается значение R в точке, определяемой соотношением:

$$x_2 = x_1 + h_{\min} F_{s-3}. \quad (3.6.68)$$

6. Если шаг оказался удачным, т.е.

$$R(x_2) < R(x_1), \quad (3.6.69)$$

то рассчитывается значение R в точке, определяемой соотношением

$$x_3 = x_2 + h_{\min} F_{s-4}. \quad (3.6.70)$$

Если шаг оказался неудачным, т.е. $R(x_2) > R(x_1)$, то x_3 определяется по соотношению

$$x_3 = x_1 - h_{\min} F_{s-4}. \quad (3.6.71)$$

Процедура продолжается последовательно до тех пор, пока не будут исчерпаны все числа Фибоначчи в убывающей последовательности.

На рис. 3.52 показана процедура поиска при $N = 21$ ($s = 7$), что отвечает точности поиска порядка 5%.




Рис. 3.52. Графическая иллюстрация метода с использованием чисел Фибоначчи

Метод Дэвиса, Свенна, Кемпи (ДСК) и метод Пауэлла

В отличие от известных методов (золотое сечение, числа Фибоначчи и т.д.) наиболее эффективными оказываются методы, в группе которых текущая точка $\bar{x}$ вблизи $\bar{x}^*$ (оптимальная точка) определяется с помощью экстраполяции и интерполяции. В качестве примера рассмотрим два алгоритма: Дэвиса, Свенна и Кемпи (алгоритм ДСК) и метод Пауэлла.

При одномерном поиске по алгоритму ДСК проводятся возрастающие по величине шаги до тех пор, пока не будет пройден минимум, а затем выполняется квадратичная интерполяция.

Алгоритм поиска следующий.

Шаг 1. Вычислить $R(x)$ в начальной точке x_0 . Если $R(x_0 + \Delta x) \leq R(x_0)$, то возврат на шаг 2, в противном случае $\Delta x = -\Delta x$.

Шаг 2. Вычислить $x_{(k+1)} = x_k + \Delta x$.

Шаг 3. Вычислить $R(x_{(k+1)})$.

Шаг 4. Если $R(x_{(k+1)}) \leq R(x_k)$, удвоить Δx и вернуться к шагу 2 при $k = k + 1$. Если




Рис. 3.53. Графическая иллюстрация метода ДСК

$R(x_{k+1}) > R(x_k)$, обозначить x_{k+1} через x_m , $x_k = x_{m-1}$ и т.д. Уменьшить Δx пополам и вернуться к шагам 2, 3 для еще только одного вычисления.

Шаг 5. Из четырех равностоящих значений $x = \{x_{m+1}, x_m, x_{m-1}, x_{m-2}\}$ исключить либо x_m , либо x_{m-2} в зависимости от удаленности значения $R(x)$ от наименьшего значения $R(x)$. Пусть x^a, x^b и x^c оставшиеся три значения x , где x^b — центральная точка, а $x^a = x^b - \Delta x$, $x^c = x^b + \Delta x$.

Шаг 6. Провести квадратичную интерполяцию для определения x^* , обеспечивающей минимум параболы, проходящей через x^a, x^b и x^c :

$$x^* = x^b + \frac{\Delta x [R(x^a) - R(x^c)]}{2[R(x^a) - 2R(x^b) + R(x^c)]}.$$

На этом заканчивается первый этап метода ДСК. При желании процедуру можно повторить из точки x^* или x^c , если $R(x^c) < R(x^*)$, уменьшив Δx (рис. 3.53).

В алгоритме Пауэлла квадратичная аппроксимация проводится путем использования первых трех точек, полученных в направлении поиска. Затем определяется точка $\tilde{x}^*$, соответствующая минимуму квадратичной функции. Такая квадратичная аппроксимация продолжается до тех пор, пока с требуемой точностью не обнаруживается экстремум $R(x)$.

Алгоритм Пауэлла строится следующим образом (рис. 3.54).

Шаг 1. От начальной точки $x^{(1)}$ нужно перейти к $x^{(2)} = x^{(1)} + \Delta x$.

Шаг 2. Вычислить $R(x^{(1)})$ и $R(x^{(2)})$.

Шаг 3. Если $R(x^{(1)}) > R(x^{(2)})$, положить $x^{(3)} = x^{(1)} + 2\Delta x$.

Если $R(x^{(1)}) \leq R(x^{(2)})$, положить $x^{(3)} = x^{(1)} - \Delta x$.

Шаг 4. Вычислить $R(x^{(3)})$.

Шаг 5. Вычислить приближенное значение x в точке минимума $R(x)$ по следующей формуле:

$$\tilde{x}^* = -\frac{1}{2} \frac{[(x^{(2)})^2 - (x^{(3)})^2]R(x^{(1)}) + [(x^{(3)})^2 - (x^{(1)})^2]R(x^{(2)}) + [(x^{(1)})^2 - (x^{(2)})^2]R(x^{(3)})}{(x^{(2)} - x^{(3)})R(x^{(1)}) + (x^{(3)} - x^{(1)})R(x^{(2)}) + (x^{(1)} - x^{(2)})R(x^{(3)})}.$$

Шаг 6. Если $\tilde{x}^*$ и любое из значений $x = \{x^{(1)}, x^{(2)}, x^{(3)}\}$, соответствующих минимуму $R(x)$, отличаются друг от друга меньше, чем на заданную точность, то закончить поиск. В противном случае, вычислить $R(\tilde{x}^*)$ и исключить из множества $\{x^{(1)}, x^{(2)}, x^{(3)}\}$ то значение x , которое соответствует наихудшему (наибольшему, см. рис. 3.54) значению $R(x)$, однако если, при этом не будет потерян интервал, в котором находится

экстремум $R(x)$. В этом случае следует исключить x так, чтобы сохранялся этот интервал. Перейти к шагу 5.

Наиболее эффективной оказалась комбинация методов ДСК и Пауэлла. Комбинированный алгоритм ДСК–Пауэлла состоит из одного этапа (шаги с 1 по 6) алгоритма ДСК, на котором определяется интервал, включающий экстремум $R(x)$, шага 6 алгоритма Пауэлла и затем, если это необходимо, шагов 5 и 6 алгоритма Пауэлла.




Рис. 3.54. Графическая иллюстрация метода Пауэлла

Прямые методы поиска экстремума функции многих переменных, не использующие производные (методы нулевого порядка)

Метод сканирования

Как и в случае одной переменной, метод сканирования для случая многих переменных заключается в последовательном просмотре значений критерия оптимальности в ряде точек, принадлежащих области изменения непрерывных переменных, и нахождении среди них такой, в которой критерий оптимальности имеет минимальное (максимальное) значение. Точность метода определяется тем, насколько плотно располагаются выбранные точки.

Метод заключается в следующем. Исследуется целевая функция вдоль одного выбранного направления (вдоль одной из координатных осей) с шагом h_1 . В каждой точке вычисляется и запоминается значение целевой функции. После того как весь диапазон изменения этой переменной исследован и для него найдено минимальное (максимальное) значений целевой функции, изменяется значение другой переменной на величину шага h_2 и опять исследуется диапазон первой переменной, в котором снова определяется искомый экстремум, и т.д. После нахождения всех экстремумов находится искомый глобальный экстремум.

Графическое представление поиска экстремума для случая двух переменных приведено на рис. 3.55.

Для произвольного числа переменных шаг по каждой следующей переменной производится после того, как завершен цикл по предыдущей.

Если имеются ограничения, то точки, которые не удовлетворяют уравнениям (или неравенствам) ограничений исключаются, и в них не вычисляются значения критерия R . Однако каждую точку требуется проверять относительно ограничений. Если переменных много, то такого рода проверка также требует длительного времени. Прием проверки ограничений типа равенств может быть представлен в следующем виде:




Рис. 3.55. Графическое представление поиска экстремума для случая двух переменных методом сканирования

$$x_j = f(x_1, x_2, \dots, x_{j-1}, x_{j+1}, \dots, x_n), \quad (3.6.72)$$

при этом поиск ведется по $(n-1)$ переменной, а значение x_j рассчитывается из соотношения (3.6.72). Разумеется, что x_j должно проверяться на допустимый диапазон его изменения.

Если относительная точность поиска равна ε по каждой из переменных, то количество вычислений целевой функции, необходимых для поиска экстремума, составит

$$S = (1/\varepsilon)^n, \quad (3.6.73)$$

где n — число переменных.

Этот метод имеет существенный недостаток, связанный с тем, что число вычислений при определении положения оптимума очень велико и возрастает в показательной степени от размерности решаемой задачи. Преимущество метода — простота, возможность определения глобального экстремума. Метод может быть использован для грубого анализа областей расположения экстремумов.

Метод поочередного изменения переменных (метод Гаусса—Зейделя)




Рис. 3.56. Путь поиска методом поочередного изменения переменных

В этом методе движение к оптимуму происходит по каждой из осей до частного экстремума. Они чередуются. Путь поиска показан на рис. 3.56.

Первая ось, по которой осуществляется поиск минимума (максимума), выбирается произвольно. Частный экстремум (по одной переменной) может быть найден любым из методов поиска экстремума функции одной переменной.

После того как найден частный минимум (максимум) по первой оси, начинается поиск минимума (максимума) по второй оси при условии, что значение первой переменной равно найденному минимуму (максимуму) на первой оси. Далее определяется минимум (максимум) на второй оси и, с учетом изложенного, осуществляется поиск по третьей, четвертой и т.д. оси. Процесс последовательно продолжается до тех пор, пока не будет достигнута заданная точность локализации экстремума, т.е. если шаг по каждой из осей приводит к возрастанию функции, а величина шага меньше или равна заданной точности поиска, то расчет закончен.

Метод пробных движений

В этом методе дается приращение по всем переменным

$$x_i^{j+1} = x_i^j + \Delta x_i^{j+1}, \quad (3.6.74)$$

где i — номер переменной; j — номер шага, и вычисляются значения целевой функции.

Из всех опробованных направлений выбирается то, в котором уменьшение (увеличение) целевой функции наибольшее. В этом направлении делается рабочий шаг h , больший Δx_i^{j+1} , и находится новая точка, из которой делаются пробные движения. Процедура повторяется до достижения заданной точности поиска.

Поиск по деформируемому многограннику

Поиск по деформируемому многограннику (метод Нелдера и Мида) основан на использовании нерегулярных многогранников (деформируемых симплексов). Для случая двух переменных регулярный симплекс — равносторонний треугольник (три точки); в случае трех переменных — тетраэдр (четыре точки) и т.д. (рис. 3.57).

При поиске минимума целевая функция может быть вычислена в каждой из вершин симплекса: из вершины, где целевая функция максимальна (точка A) проводится проектирующая прямая через центр тяжести симплекса. Затем точка A исключается и строится новый симплекс, называемый отраженным из оставшихся прежних точек и одной новой точки B , расположенной на проектирующей прямой на заданном расстоянии от центра тяжести.

Наличие оврагов и хребтов целевой функции приводит к необходимости изменять размеры и форму симплекса в процессе поиска.

В методе Нелдера и Мида минимизируется функция n независимых переменных с использованием $(n + 1)$ вершин деформируемого многогранника. Каждая величина идентифицируется вектором $\bar{x}$. Вершина, в которой значение $R(\bar{x})$ максимально, проектируется через центр тяжести оставшихся вершин. Улучшенные значения целевой функции находятся последовательной заменой точки с максимальным значением $R(\bar{x})$ на более «хорошие» точки, пока не будет найден минимум $R(\bar{x})$.

Алгоритм метода Нелдера—Мида является следующим.

Пусть $\bar{x}_i^{(k)} = [x_{i1}^{(k)}, \dots, x_{ij}^{(k)}, \dots, x_{in}^{(k)}]^T$, $i = 1, \dots, n+1$ является i -й вершиной (точкой) в n -мерном пространстве E^n на k -м этапе поиска $k = 0, 1, \dots$, и пусть значение целевой функции в $\bar{x}_i^{(k)}$ равно $R(\bar{x}_i^{(k)})$. Кроме того, отметим те векторы $\bar{x}$ многогранника, которые дают максимальное и минимальное значения $R(\bar{x})$.

Определим

$$R(\bar{x}_h^{(k)}) = \max\{R(\bar{x}_1^{(k)}), \dots, R(\bar{x}_{n+1}^{(k)})\}, \text{ где } 1 \leq h \leq n+1, \quad (3.6.75)$$

и

$$R(\bar{x}_\ell^{(k)}) = \min\{R(\bar{x}_1^{(k)}), \dots, R(\bar{x}_{n+1}^{(k)})\}, \text{ где } 1 \leq \ell \leq n+1. \quad (3.6.76)$$

Пусть $\bar{x}_{n+2}^{(k)}$ — центр тяжести всех вершин, исключая $\bar{x}_h^{(k)}$. Тогда координаты этого центра тяжести определяются формулой:

$$x_{n+2,j}^{(k)} = \frac{1}{n} \left[\sum_{i=1}^{n+1} x_{ij}^{(k)} - x_{hj}^{(k)} \right]; \quad j = 1, \dots, n, \quad (3.6.77)$$

где j — координатное направление.

Начальный многогранник обычно выбирается в виде регулярного симплекса с точкой 1 в качестве начала координат. Процедура отыскания $\min R(\bar{x})$ состоит из следующих операций.

1. Отражение — проектирование $\bar{x}_h^{(k)}$ через центр тяжести в соответствии с соотношением

$$\bar{x}_{n+3}^{(k)} = \bar{x}_{n+2}^{(k)} + \alpha(\bar{x}_{n+2}^{(k)} - \bar{x}_h^{(k)}), \quad (3.6.78)$$

где $\alpha > 0$ — коэффициент отражения; $\bar{x}_{n+2}^{(k)}$ — центр тяжести (3.6.77).

2. Растяжение. Если $R(\bar{x}_{n+3}^{(k)}) \leq R(\bar{x}_\ell^{(k)})$, то вектор $(\bar{x}_{n+3}^{(k)} - \bar{x}_{n+2}^{(k)})$ растягивается в соответствии с соотношением




Рис. 3.57. Графическая иллюстрация определения новых точек при поиске по деформируемому многограннику

$$\bar{x}_{n+4}^{(k)} = \bar{x}_{n+2}^{(k)} + \gamma(\bar{x}_{n+3}^{(k)} - \bar{x}_{n+2}^{(k)}), \quad (3.6.79)$$

где $\gamma > 1$ — коэффициент растяжения. Если $R(\bar{x}_{n+4}^{(k)}) < R(\bar{x}_l^{(k)})$, то $\bar{x}_h^{(k)}$ заменяется на $\bar{x}_{n+4}^{(k)}$ и процедура продолжается снова с операции 1 при $k = k + 1$. В противном случае $\bar{x}_h^{(k)}$ заменяется на $\bar{x}_{n+3}^{(k)}$ и также осуществляется переход к операции 1 при $k = k + 1$.

3. Сжатие. Если $R(\bar{x}_{n+3}^{(k)}) > R(\bar{x}_l^{(k)})$ для всех $i \neq h$, то вектор $(\bar{x}_h^{(k)} - \bar{x}_{n+2}^{(k)})$ сжимается в соответствии с формулой

$$\bar{x}_{n+3}^{(k)} = \bar{x}_{n+2}^{(k)} + \beta(\bar{x}_h^{(k)} - \bar{x}_{n+2}^{(k)}), \quad (3.6.80)$$

где $0 < \beta < 1$ — коэффициент сжатия. Затем $\bar{x}_h^{(k)}$ заменяется на $\bar{x}_{n+3}^{(k)}$ и происходит возврат к операции 1.

4. Редукция. Если $R(\bar{x}_{n+3}^{(k)}) > R(\bar{x}_h^{(k)})$, все векторы $(\bar{x}_i^{(k)} - \bar{x}_l^{(k)})$ для $i = 1, \dots, n+1$ уменьшаются в два раза с отсчетом от $\bar{x}_l^{(k)}$ по формуле

$$\bar{x}_i^{(k)} = \bar{x}_l^{(k)} + 0.5(\bar{x}_i^{(k)} - \bar{x}_l^{(k)}), \quad i = 1, \dots, n+1. \quad (3.6.81)$$

Затем осуществляется переход к операции 1. Критерий окончания поиска, использованный Нелдером и Мидом, имеет следующий вид:

$$\left\{ \frac{1}{n+1} \sum_{i=1}^{n+1} R(\bar{x}_i^{(k)}) - R(\bar{x}_{n+2}^{(k)})^2 \right\}^{1/2} \leq \varepsilon, \quad (3.6.82)$$

где ε — произвольное малое число.

Деформируемый многогранник адаптируется к топографии целевой функции, вытягиваясь вдоль длинных наклонных плоскостей, изменяя направление в изогнутых впадинах и сжимаясь в окрестности минимума.

Методы случайного поиска

В основе методов случайного поиска лежит стратегия нахождения экстремума функции путем перебора совокупностей случайных значений независимых переменных. Эти методы, получившие общее название методов Монте-Карло, успешно применяются с использованием вычислительных машин для решения задач обращения матриц, нахождения собственных значений и собственных векторов матриц, решения систем алгебраических уравнений и целого ряда других задач. Общим для всех методов случайного поиска является генерирование и использование случайных чисел в процессе поиска, отличием — стратегия движения к экстремуму.

Из методов случайного поиска наибольшее распространение получил метод *случайного направления*. При использовании этого метода очередное приближение определяется соотношением

$$x_i^{(k+1)} = x_i^{(k)} + h^{(k)} \beta_i^{(k)}, \quad i = 1, 2, \dots, n, \quad (3.6.83)$$

где $h^{(k)}$ — параметр шага; β_i — компонент случайного вектора $\bar{\beta}$.

Если значение функции $f(\bar{x}^{(k+1)})$ в новой точке оказывается меньше предыдущего $f(\bar{x}^{(k)})$, то в качестве очередного приближения принимаются последние значения неизвестных $\bar{x}^{(k+1)}$, в противном случае остаются предыдущие значения $\bar{x}^{(k)}$. Процедура генерирования случайного направления (вектора $\bar{\beta}^{(k)}$) повторяется до тех пор, пока не будет найден экстремум функции.

Известно несколько модифицированных методов случайного поиска. Так, например, метод случайных направлений с обратным шагом рекомендует при неудачном шаге делать сразу же шаг в обратном направлении, равном $-h^{(k)}\bar{\beta}^{(k)}$, что позволя-

ст существенно сократить время поиска. Если и обратный шаг окажется неудачным, то можно из предыдущей точки сделать новый шаг, сгенерировав новый случайный вектор направления, или перейти к поиску с меньшим значением шага.

Прямые методы поиска экстремума функции многих переменных, использующие производные (методы первого и второго порядка)

Методы оптимизации с использованием производных, как правило, более эффективны в смысле скорости сходимости, чем методы, не использующие производные. Они делятся на методы первого и второго порядка, в которые соответственно используются первые и вторые производные. Проблема, однако, состоит в том, что на практике редко удаётся аналитически вычислить первые, не говоря уже о вторых производных. В свою очередь, приближённый расчёт производных численными методами (см. разд. 3.4) трудоёмок и трудно оценить погрешность полученных при этом результатов.

Метод градиента

К градиентным методам относится совокупность методов, стратегия движения к экстремуму в которых основана на вычислении значений частных производных целевой функции $R(x_1, x_2, \dots, x_n)$ и которые являются компонентами *градиента*:

$$\bar{\nabla}R(\bar{x}) = \overline{\text{grad}R(\bar{x})} = \frac{\partial R}{\partial x_1} \bar{\ell}_1 + \dots + \frac{\partial R}{\partial x_n} \bar{\ell}_n, \quad (3.6.84)$$

где $\bar{\ell}$ — единичные векторы для соответствующих осей координат.

Известно, что *градиент* (3.6.84) является вектором, который определяет направление наискорейшего возрастания целевой функции $R(\bar{x})$ (в противоположность *антиградиенту*, определяющему направление наискорейшего убывания целевой функции $R(\bar{x})$).

Координаты новой точки в результате шага, выполненного по направлению вектора градиента из точки с координатами $\bar{x}^* = (x_1^*, x_2^*, \dots, x_n^*)$, определяются:

$$x_j = x_j^* + h \frac{\partial R}{\partial x_j}(\bar{x}^*); \quad j = 1, \dots, n \quad (3.6.85a)$$

или с учётом нормировки с использованием нормы градиента $\|\bar{\nabla}R(\bar{x})\|$:

$$x_j = x_j^* + \tilde{h} \frac{\frac{\partial R}{\partial x_j}(\bar{x}^*)}{\|\bar{\nabla}R(\bar{x})\|}; \quad j = 1, \dots, n, \quad (3.6.85b)$$

где h и $\tilde{h}$ — факторы шага.

При этом *норма градиента* $\|\bar{\nabla}R(\bar{x})\|$ определяется по формуле:

$$\|\bar{\nabla}R(\bar{x})\| = \|\overline{\text{grad}R(\bar{x})}\| = \sqrt{\left(\frac{\partial R}{\partial x_1}\right)^2 + \left(\frac{\partial R}{\partial x_2}\right)^2 + \dots + \left(\frac{\partial R}{\partial x_n}\right)^2}, \quad (3.6.86)$$

где $\frac{\partial R}{\partial x_1}, \frac{\partial R}{\partial x_2}, \dots, \frac{\partial R}{\partial x_n}$ — компоненты градиента.

Одним из важных свойств градиента функции $\overline{\text{grad}R(\bar{x})}$ является то, что он направлен по нормали к линиям постоянного уровня целевой функции $R(\bar{x})$ (рис. 3.58). Поскольку градиент функции даёт направление, в котором функция возрастает с максимальной скоростью, то направление градиента применяется для поиска экстр-




Рис. 3.58. Траектория поиска экстремума методом градиента

ремума в методах, использующих вычисление частных производных целевой функции.

В этом методе поиск экстремума функции осуществляется последовательно — шагами в направлении градиента.

Алгоритм поиска имеет вид:

$$x_i^{j+1} = x_i^j + h^j \frac{\partial R}{\partial x_i}, \quad (3.6.87)$$

где индекс i — номер переменной; индекс j — номер шага поиска.

Итак, в начальной точке поиска $\bar{x}^0 = (x_1^0, x_2^0, \dots, x_n^0)$ вычисляется градиент функции, а затем находятся координаты положения точки $\bar{x}^1 = (x_1^1, x_2^1, \dots, x_n^1)$:

$$\begin{cases} x_1^1 = x_1^0 + h \frac{\partial R}{\partial x_1}(\bar{x}^0); \\ x_2^1 = x_2^0 + h \frac{\partial R}{\partial x_2}(\bar{x}^0); \\ \dots \\ x_n^1 = x_n^0 + h \frac{\partial R}{\partial x_n}(\bar{x}^0). \end{cases} \quad (3.6.88)$$

В полученной точке $\bar{x}^1 = (x_1^1, x_2^1, \dots, x_n^1)$ снова вычисляется градиент функции и находится точка $\bar{x}^2 = (x_1^2, x_2^2, \dots, x_n^2)$, координаты которой получаются по тому же алгоритму (3.6.87):

$$\begin{cases} x_1^2 = x_1^1 + h \frac{\partial R}{\partial x_1}(\bar{x}^1); \\ x_2^2 = x_2^1 + h \frac{\partial R}{\partial x_2}(\bar{x}^1); \\ \dots \\ x_n^2 = x_n^1 + h \frac{\partial R}{\partial x_n}(\bar{x}^1). \end{cases} \quad (3.6.89)$$

Величина h обычно выбирается либо постоянной, либо пропорциональной значению производной в данной точке и носит название фактора шага. Траектория поиска показана на рис. 3.58. Процесс продолжается до тех пор, пока экстремум не будет найден с достаточной точностью, т.е. пока не будут выполнены неравенства

$$\begin{aligned} R(x_1^{t+1}, x_2^{t+1}, \dots, x_n^{t+1}) &< R(x_1^t, x_2^t, \dots, x_n^t); \\ |x_i^{t+1} - x_i^t| &< \varepsilon_i, \end{aligned} \quad (3.6.90)$$

где ε_i — заданная точность поиска.

Метод наискорейшего спуска

Метод наискорейшего спуска напоминает метод градиента, т.е. в исходной точке определяется направление наискорейшего возрастания функции (градиент). Затем вдоль этого направления делается не один шаг, как в методе градиента, а продолжа-

ется движение до нахождения максимума вдоль этого направления. Затем в точке максимума вновь определяют градиент, и осуществляется движение в направлении этого градиента до частного максимума и т.д. до тех пор, пока не находится абсолютный максимум функции цели (путь движения к максимуму изображен на рис. 3.59).

Направление, противоположное нормированному (единичному) градиенту $R(\bar{x})$, т.е. направление наискорейшего спуска, определяется в точке $\bar{x}^{(k)}$ по формуле:

$$\bar{E}^{(k)} = \frac{\bar{\nabla} R(\bar{x}^{(k)})}{\|\bar{\nabla} R(\bar{x}^{(k)})\|}, \quad (3.6.91)$$

где $\bar{E}^{(k)}$ — единичный вектор в направлении градиента $\bar{\nabla} R(\bar{x}^{(k)})$ и, соответственно, $\Delta \bar{x}^{(k)}$.

На k -м этапе переход из точки $\bar{x}^{(k)}$ в точку $\bar{x}^{(k+1)}$ описывается как:

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} - \Delta \bar{x}^{(k)} = \bar{x}^{(k)} - \lambda^{(k)} \bar{E}^{(k)} = \bar{x}^{(k)} - \lambda^{(k)} \bar{\nabla} R(\bar{x}^{(k)}). \quad (3.6.92)$$

Подстановка (3.6.91) в (3.6.92) дает следующее соотношение для метода наискорейшего спуска:

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} - \frac{\lambda^{(k)} \bar{\nabla} R(\bar{x}^{(k)})}{\|\bar{\nabla} R(\bar{x}^{(k)})\|}, \quad (3.6.93)$$

но поскольку выражение $\frac{\lambda^{(k)}}{\|\bar{\nabla} R(\bar{x}^{(k)})\|}$ — скалярная величина, то оно может быть заменено некоторым числом $\lambda^{*(k)}$, т.е.

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} - \lambda^{*(k)} \bar{\nabla} R(\bar{x}^{(k)}). \quad (3.6.94)$$

Поиск в соответствии с (3.6.94) осуществляется многократно, причем для каждого направления градиента осуществляется минимизация функции $R(\bar{x}^{(k)})$. Это может осуществляться формально также [см. (3.6.91) — (3.6.93)] путем вычисления $\lambda^{(k)}$ из уравнения:

$$\frac{dR(\bar{x}^{(k)} - \lambda \bar{E}^{(k)})}{d\lambda} = 0. \quad (3.6.95)$$

Но чаще используют тот или иной метод одномерного поиска для определения величин $\lambda^{(k)}$ или $\lambda^{*(k)}$, минимизирующей на k -м шаге поиска целевую функцию.

Метод наискорейшего спуска позволяет найти экстремум при минимальном объеме вычислений. Метод особенно выгодно использовать в том случае, когда градиент функции изменяется не резко. Очевидно, что вблизи экстремума метод наискорейшего спуска вырождается в метод градиента. В качестве критерия окончания поиска можно использовать те же критерии, что и в методе градиента.

Метод релаксаций

Метод также использует производные, в частности, первые производные целевой функции и состоит в нахождении осевого направления, вдоль которого целевая функция возрастает наиболее быстро. Для этого в начальной точке поиска определяются производные функции по всем переменным $\partial R / \partial x_i$. По той оси, вдоль которой про-




Рис. 3.59. Путь поиска экстремума методом наискорейшего спуска

изводная наибольшая, и производится движение до частного минимума одномерным методом поиска. Затем анализ производных вновь повторяется. Критерием окончания поиска может служить следующее положение: если при движении из очередной точки не наблюдается дальнейшее возрастание целевой функции, то максимум найден.

Алгоритм поиска при методе релаксаций имеет вид:

$$x_i^{j+1} = x_i^j + h^j \cdot \text{sign} \left(\frac{\partial R}{\partial x_i} \right), \quad (3.6.96)$$

где x_i^j — значение переменной, по которой происходит оптимизация на данном шаге

$$\text{sign } y = \begin{cases} 1, & \text{если } y > 0; \\ 0, & \text{если } y = 0; \\ -1, & \text{если } y < 0. \end{cases} \quad (3.6.97)$$

а h^j — фактор шага, величина которого изменяется в процессе поиска.

Обычно шаг выбирается так: вначале он принимается равным числу $h^1 = \delta$, затем делается еще один шаг в этом направлении $h^2 = h^1$; если шаг оказался успешным, то он удваивается $h^3 = 2h^2$. Если же следующий шаг оказался не успешным, то из предыдущей точки, в которой был удачный шаг, делаются шаги в 2 раза меньше, чем последний удачный. Уменьшение величины шага в области максимума производится до заданного значения, определяемого желаемой точностью.

Метод релаксаций можно рассматривать как комбинацию методов, использующих производные.

Метод Ньютона

Направление поиска, соответствующее наискорейшему спуску, можно интерпретировать как следствие линейной аппроксимации целевой функции. С другой стороны, методы вторых производных (метод Ньютона) возникли из квадратичной аппроксимации $R(\bar{x})$, определяемой следующим уравнением:

$$R(\bar{x}^{(k+1)}) = R(\bar{x}^{(k)}) + \nabla^T R(\bar{x}^{(k)}) \Delta \bar{x}^{(k)} + \frac{1}{2} (\Delta \bar{x}^{(k)})^T \nabla^2 R(\bar{x}^{(k)}) \Delta \bar{x}^{(k)}. \quad (3.6.98)$$

Используя (3.6.98), минимум $R(\bar{x})$ в направлении $\Delta \bar{x}^{(k)}$ определяется дифференцированием $R(\bar{x})$ по каждой из компонент $\Delta \bar{x}$ и приравниванием к нулю полученных выражений, что приводит к следующему уравнению:

$$\Delta \bar{x}^{(k)} = - \left[\nabla^2 R(\bar{x}^{(k)}) \right]^{-1} \bar{\nabla} R(\bar{x}^{(k)}), \quad (3.6.99)$$

где $[\nabla^2 R(\bar{x}^{(k)})]^{-1}$ — матрица, обратная матрице Гесса $H(\bar{x}^{(k)})$ (3.6.44).

Подставляя (3.6.99) в (3.6.92), получаем:

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} - \left[\nabla^2 R(\bar{x}^{(k)}) \right]^{-1} \bar{\nabla} R(\bar{x}^{(k)}). \quad (3.6.100)$$

Здесь и направление, и величина шага точно определены. В случае, если $R(\bar{x})$ — квадратичная функция, то для достижения минимума достаточно одного шага. Но в общем случае минимума достичь за один шаг нельзя, и поэтому уравнение (3.6.100) обычно приводят к виду (3.6.93) путем введения специального параметра длины шага:

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} - \lambda^{(k)} \frac{\left[\nabla^2 R(\bar{x}^{(k)}) \right]^{-1} \bar{\nabla} R(\bar{x}^{(k)})}{\left\| \left[\nabla^2 R(\bar{x}^{(k)}) \right]^{-1} \bar{\nabla} R(\bar{x}^{(k)}) \right\|}. \quad (3.6.101)$$

Отношение $\lambda^{(k)} / \left\| \bar{\nabla}^2 R(\bar{x}^{(k)})^{-1} [\bar{\nabla} R(\bar{x}^{(k)})] \right\|$ – некоторая скалярная величина $\lambda^{*(k)}$, поэтому (3.6.101) чаще приводят к виду:

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} - \lambda^{*(k)} \bar{H}^{-1}(\bar{x}^{(k)}) \bar{\nabla} R(\bar{x}^{(k)}). \quad (3.6.102)$$

Здесь направление поиска задается вектором:

$$\bar{S}^{(k)} = -\bar{H}^{-1}(\bar{x}^{(k)}) \bar{\nabla} R(\bar{x}^{(k)}). \quad (3.6.103)$$

Применение подобных методов, использующих для определения экстремума вторые производные, довольно затруднительно, хотя они и обладают при прочих равных условиях очень высокой эффективностью.

Необходимо отметить следующие недостатки метода Ньютона.

1. Необходимо обращать матрицу Гесса $H(\bar{x})$, и поэтому используемая процедура решения должна обеспечивать положительную определенность обратной матрицы (3.6.23).
2. Требуется аналитическое вычисление вторых частных производных целевой функции.

Анализ методов решения *задач нелинейного программирования* при отсутствии ограничений приводит к выводу, что градиентные методы и методы, использующие вторые производные, сходятся быстрее, чем методы поиска экстремума, не использующие производные. Тем не менее, применяя на практике методы, использующие производные, приходится сталкиваться с двумя главными препятствиями.

Во-первых, в задачах с большим количеством переменных довольно трудно или практически невозможно получить производные в виде аналитических выражений, необходимых для алгоритмов, использующих градиент или вторые производные.

Хотя вычисление аналитических производных можно заменить вычислением с помощью разностей, возникающая при этом ошибка может ограничить применение подобной аппроксимации в случаях оврага и в окрестности минимума.

Во-вторых, градиентные методы требуют регулярности и непрерывности целевой функции, т.е. существования непрерывных частных производных.

К недостаткам градиентных методов по сравнению с методами поиска можно отнести количество затраченного времени при подготовке задачи к решению.

Вследствие вышесказанного, методы прямого поиска нулевого порядка, не использующих производные, оказываются зачастую более удовлетворительными с точки зрения их использования, чем градиентные.

3.6.5. Численные методы оптимизации при наличии ограничений

Все методы оптимизации при наличии ограничений делятся на два класса: методы сведения к задаче безусловного экстремума без ограничений и методы прямого решения задач с ограничениями.

Среди методов, сводящих задачу с ограничениями к безусловной оптимизации, наиболее широко распространены методы штрафных функций.

Методы штрафных функций

При решении задач оптимизации химико-технологической системы существует, как правило, как ряд ограничений типа равенств (например, значения потоков в местах разрывов в схемах с обратной связью), так и ограничения типа неравенств (например, технологические ограничения по диапазону концентраций, температур, давления и т.д.).

Тогда в общем виде задачу можно сформулировать следующим образом:
минимизировать

$$R(\bar{x}), \quad \bar{x}^{\min} \leq \bar{x} \leq \bar{x}^{\max} \quad (3.6.104)$$

при ограничениях

$$\varphi_i(\bar{x}) = 0, \quad i = 1, \dots, m;$$

$$g_i(\bar{x}) \geq 0, \quad i = m+1, \dots, p$$

В основу методов штрафных функций положена идея преобразования общей нелинейной задачи (3.6.6) в последовательность задач без ограничений (3.6.1) путем добавления к целевой функции одной или нескольких функций, задающих ограничения с тем, чтобы ограничения, как таковые, в задаче оптимизации не фигурировали.

Например, необходимо минимизировать функцию

$$R(x) = ax + b, \quad \text{где } x_0 \leq x \leq x_1. \quad (3.6.105)$$

Графически это изображено на рис. 3.60. Ясно, что ограничение x_1 должно сдерживать любой шаговый метод поиска, такое ограничение называется активным.

Одним из наиболее простых методов штрафа является изменение целевой функции с тем, чтобы образовать локальный экстремум в окрестности активного ограничения. С этой целью формируется новая целевая функция (штрафная функция):

$$P(x) = ax + b + (x - x_1)^2. \quad (3.6.106)$$

Тогда целевая функция будет иметь вид, показанный на рис. 3.61, и методом прохождения безусловного экстремума можно определить точку оптимума. Однако, как видно из рис. 3.61, получается точка, отстоящая от границы и, следовательно, от точного решения на величину $(x_1 - x^*)$, что не всегда удовлетворяет точности решения задачи.

Для того, чтобы удовлетворить точности, необходимо ввести некоторый множитель μ , который называется весовым коэффициентом ($\mu > 1$).

Тогда целевая функция примет вид как показано на рис. 3.62, из которого видно, что с увеличением μ $x_2^* \rightarrow x_1$, т.е. выполняется наперед заданная точность.

Аналогично можно ввести штрафную функцию для ограничений в виде равенств, тогда обобщенный критерий оптимизации для задачи типа (3.6.104) примет вид:

$$P(\bar{x}) = R(\bar{x}) + \sum_{i=1}^m \mu_i \varphi_i^2(\bar{x}) + \sum_{i=m+1}^p \mu_i g_i^2(\bar{x}), \quad (3.6.107)$$

где $\mu_i, i = 1, 2, \dots, p$ — весовые коэффициенты, а u — оператор Хевисайда, который принимает значения 0 и 1, если в точке $\bar{x}_k$ $g_i(\bar{x}_k) \geq 0$ и 1, если $g_i(\bar{x}_k) < 0$.

Таким образом, вводя штрафную функцию, мы тем самым выделяем своеобразную «стену» на границе области и чем больше μ_i , тем она «круче». Однако на этой же границе образуется овраг, который резко замедляет скорость сходимости




Рис. 3.60. Графическая иллюстрация целевой функции (3.6.105) при поиске оптимума без использования метода штрафных функций




Рис. 3.61. Графическая иллюстрация целевой функции (3.6.106) при поиске оптимума с использованием метода штрафных функций

любого метода, а для некоторых он неприменим. Поэтому выбор весовых коэффициентов тоже является своеобразной задачей, и от удачного выбора во многом зависит время решения задачи.

Теория штрафных функций достаточно хорошо разработана и основана на идее изменения целевой функции таким образом, чтобы последовательность точек, получаемых в результате применения какого-либо метода безусловной оптимизации, одновременно сходилась и к выполнению всех ограничений и к минимальному значению целевой функции.

Необходимо отметить, что оптимизация ХТП в большинстве случаев связана с решением сложных задач нелинейного программирования (НЛП) часто с овражными целевыми функциями и необходимостью использования при вычислениях ограничений первого и второго рода, что, в свою очередь, требует реализации специальных алгоритмов, позволяющих вести поиск не только локальных экстремумов, но и глобального оптимума.




Рис. 3.62. Графическая иллюстрация целевой функции (3.6.107) при поиске оптимума с использованием метода штрафных функций с различными значениями весовых коэффициентов